

Tecnológico de Monterrey

Analitica de datos y Herramientas de Inteligencia Artificial

André Heredia | A01738019

19 Octubre 2026

Actividad 5 (Evaluación)

1. Introducción

En esta actividad se aplicaron tres técnicas de modelado a los datos complementarios del socio formador: regresión lineal simple, regresión lineal múltiple y regresión logística. El objetivo fue analizar la relación entre las variables de ventas e inventario, construir modelos que las describan y comparar sus resultados.

El trabajo se realizó en Python (Visual Studio Code, con libreta Jupyter), usando pandas y numpy para el manejo de datos, statsmodels para las regresiones lineales, scikit-learn para la regresión logística y matplotlib y seaborn para las gráficas.

2. Descripción de los datos

El archivo Datos_Complementarios_CLV.xlsx contiene tres hojas:

- **Histórico_Ventas:** 21,632 registros de ventas de abril a agosto de 2026, con folio, fecha, artículo, marca, precio unitario, unidades, total neto, cliente, estado, ciudad, código postal y vendedor.
- **Existencias_15_10_2026:** 2,951 artículos con sus existencias y valor de inventario al 15 de octubre de 2026.
- **Histórico_Entradas_SAlidas:** historial de salidas por artículo desde 2019. No se utilizó porque sus claves de artículo no coinciden con las de las otras dos hojas.

Se trabajó con las hojas de ventas e inventario.

3. Preprocesamiento

Nulos. La única columna con valores nulos fue cp (código postal), con 492 registros. Como es un código y no una variable numérica con sentido para los modelos, se eliminó. También se limpió el nombre de la columna estado, que venía con espacios al final.

Registros no válidos. Se encontraron 1,612 filas con total_neto igual a cero, que corresponden a obsequios o muestras y no a ventas reales. Se eliminaron y quedaron 20,020 registros.

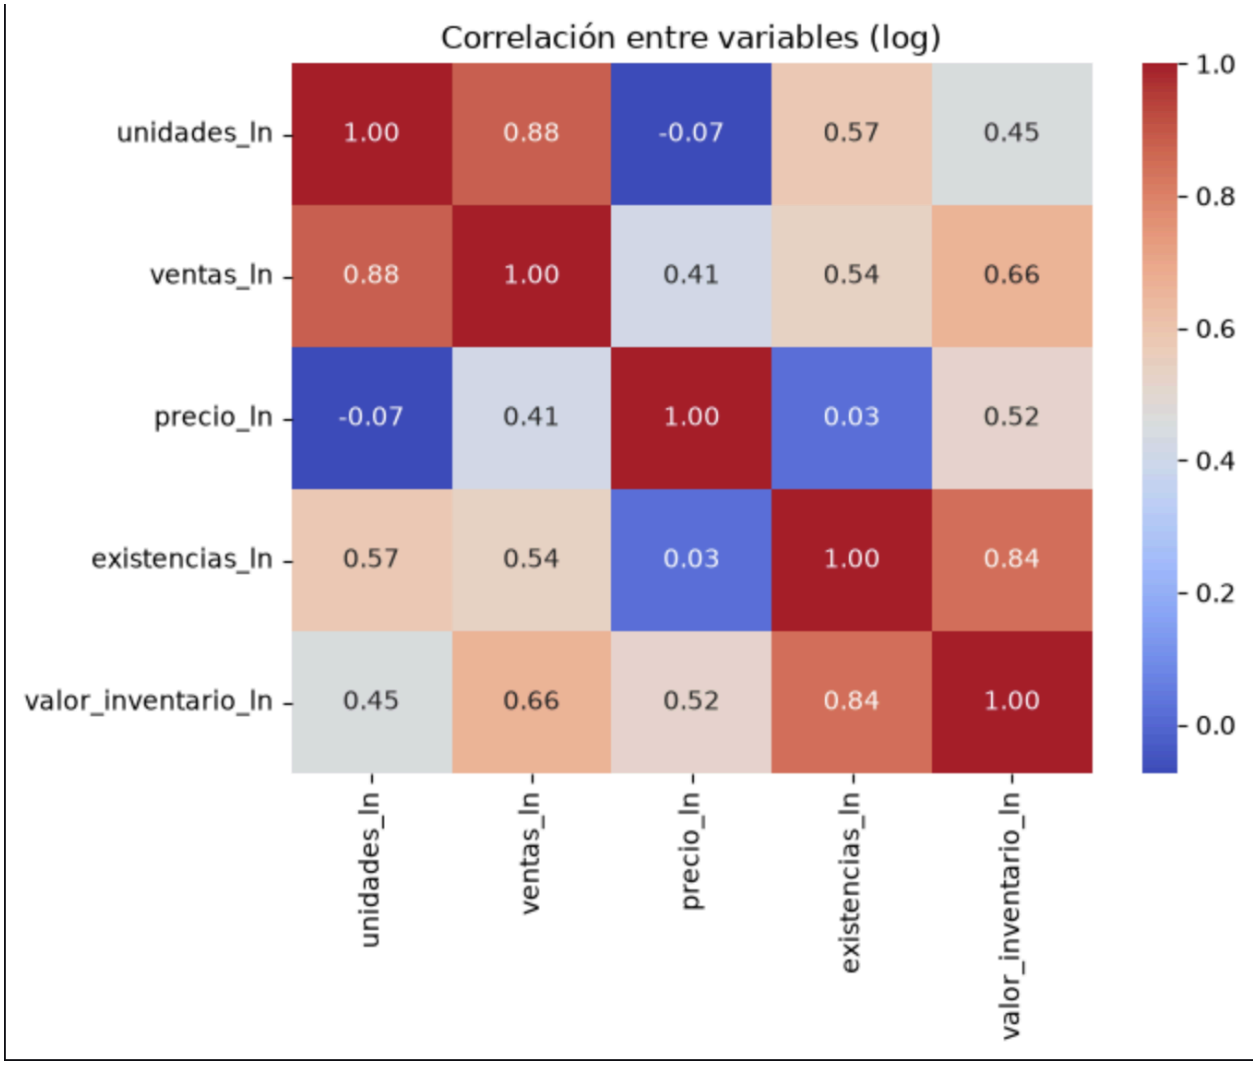
Base por artículo. Para las regresiones lineales se agruparon las ventas por artículo, calculando las unidades vendidas, las ventas totales y el precio promedio. Después se unió con la hoja de existencias para agregar las existencias y el valor de inventario. La base quedó con 1,290 artículos.

Transformaciones. Las variables presentaban una asimetría muy fuerte (por ejemplo, 22.17 en ventas y 16.80 en valor de inventario). Se aplicó logaritmo natural a todas, y la asimetría bajó a valores entre 0.16 y 0.76. Las columnas transformadas llevan el sufijo _ln.

Outliers. Se aplicó el criterio del rango intercuartílico (1.5 veces el IQR) sobre las variables ya transformadas, lo que eliminó 129 artículos. La base final quedó con 1,161 artículos. Se hizo después del logaritmo porque en escala original casi todos los productos caros habrían salido como atípicos.

4. Regresión lineal simple

Se calculó la matriz de correlación de las variables y se graficó con un heatmap. La mayor correlación fue entre unidades vendidas y ventas totales (r = 0.877), seguida de existencias con valor de inventario (0.845) y ventas con valor de inventario (0.662).

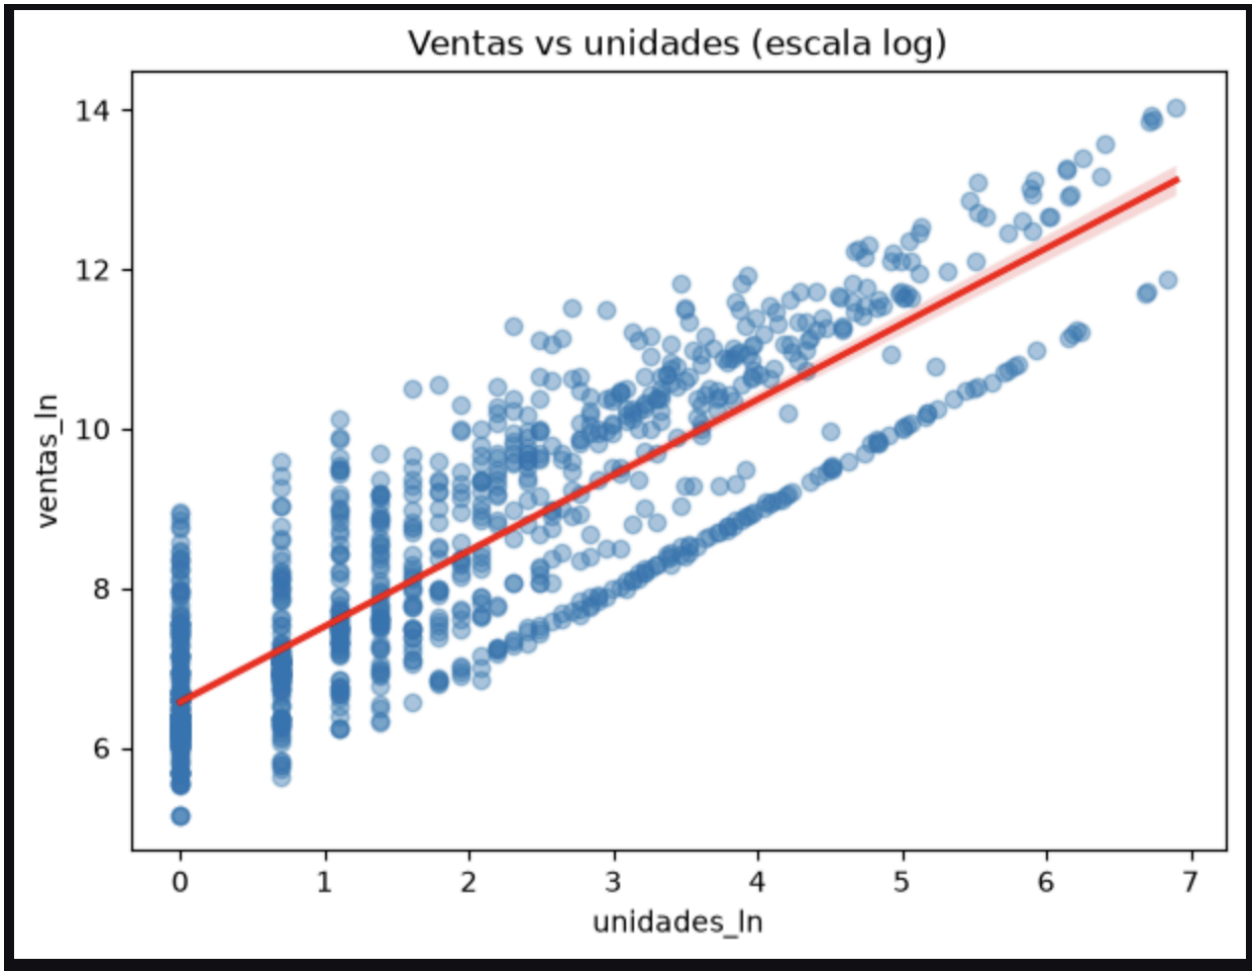


Con esas dos variables se ajustó un modelo de mínimos cuadrados ordinarios:

ln(ventas) = 6.569 + 0.949 · ln(unidades)

Parámetro	Coeficiente	Error estándar	p-valor
Intercepto	6.5694	0.0368	0.000
In(Unidades)	0.9491	0.0153	0.000

El R^2 del modelo es **0.769**, es decir, las unidades vendidas explican el 77% de la variación de las ventas. Como ambas variables están en logaritmo, el coeficiente se interpreta como una elasticidad: un aumento de 1% en las unidades vendidas se asocia con un aumento de aproximadamente 0.95% en las ventas.



5. Regresión lineal múltiple

Antes de agregar más variables se revisó la multicolinealidad con el factor de inflación de la varianza (VIF):

Variable	VIF
Unidades_In	1.52
precio_In	7.01
existencias_In	17.92
valor_inventario_In	24.31

Las existencias y el valor de inventario presentaron VIF altos y no resultaron significativas dentro del modelo completo, por lo que se descartaron. El modelo final incluye unidades y precio:

ln(ventas) = −0.027 + 0.988 · ln(unidades) + 1.005 · ln(precio)

Parámetro	**Coeficiente**	**Error estándar**	**p-valor**
Intercepto	-0.0269	0.0072	0.0002
In(Unidades)	0.9878	0.0006	0.000
In(precio)	1.0046	0.0011	0.000

El R^2 es **0.9997** (R^2 ajustado 0.9997).

Comparación con el modelo simple:

	Simple	**Múltiple**
Intercepto	6.569	-0.027
In(unidades)	0.949	0.988
In(precio)	no incluido	1.005

El R^2 subió de 0.77 a casi 1. Esto tiene sentido porque las ventas se calculan como precio por unidades, y en escala logarítmica ambos coeficientes deben ser cercanos a 1. En el modelo simple el coeficiente de las unidades quedaba subestimado (0.949) porque faltaba el precio, y el

intercepto era grande para compensar ese efecto. Al incluirlo, el coeficiente de unidades subió a 0.988 y el intercepto bajó a casi cero.

6. Regresión logística

Variable dicotómica. La base no trae una variable de dos categorías lista, por lo que se construyó es_mayoreo, que vale 1 si la línea de venta tiene 5 o más unidades y 0 en caso contrario. Solo el **14.6%** de las ventas es de mayoreo, por lo que las clases están desbalanceadas.

Manejo del desbalance. Los datos se dividieron en 70% para entrenamiento y 30% para prueba, manteniendo la proporción de clases. Se compararon tres opciones usando el precio como predictor:

Método	**Precisión (Mayoreo)**	**Recall (mayoreo)**	**F1 (Mayoreo)**
Sin ajuste	0.00	0.00	0.00
Reponderación de clases	0.19	0.55	0.28
Oversampling	0.19	0.55	0.28

Sin ajuste, el modelo predijo siempre "no mayoreo": tuvo una exactitud de 85%, pero no detectó ningún caso de la clase minoritaria. La reponderación de clases y el oversampling corrigen el problema y dan resultados prácticamente iguales, lo cual es esperable porque ambas técnicas buscan el mismo efecto.

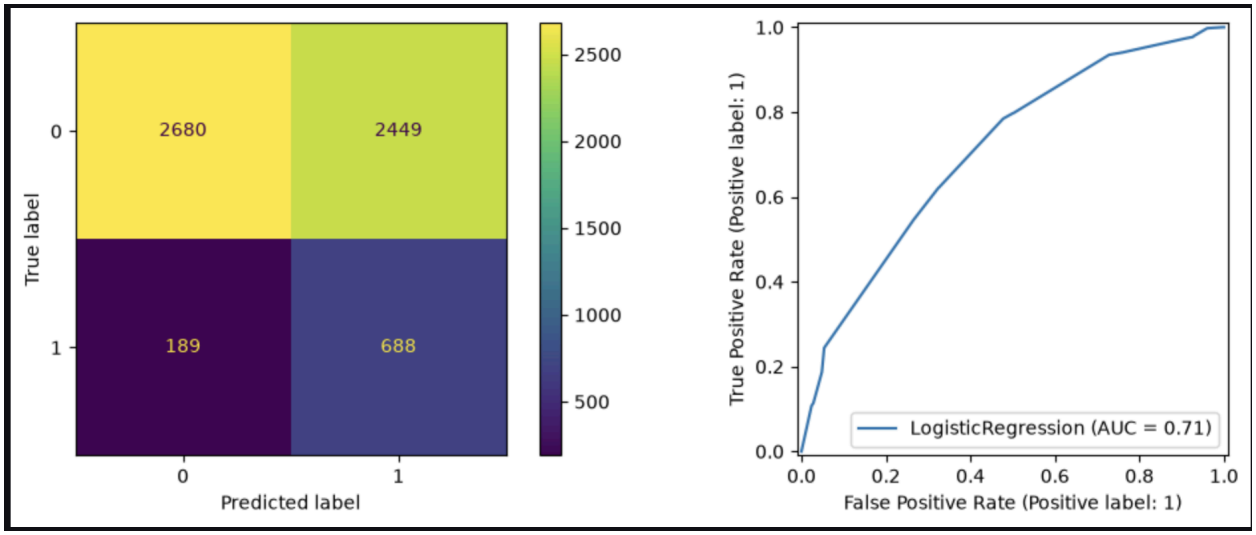
Variables dicotómicas. Para el modelo final se convirtieron las variables necesarias a 0/1, con las categorías más relevantes:

- marca_vita y marca_aidite: 1 si el artículo es de esa marca.
- edo_cdmx y edo_puebla: 1 si el cliente es de ese estado.
- precio_sobre_mediana: 1 si el precio unitario es mayor a la mediana.

Se ajustó la regresión logística con reponderación de clases. Resultados sobre el conjunto de prueba:

- Recall de mayoreo: **0.78**
- Precisión de mayoreo: 0.22
- Exactitud global: 0.56
- AUC: **0.71**

De los 877 mayoreos del conjunto de prueba, el modelo detectó 688 y dejó pasar 189. A cambio, generó 2,449 falsos positivos.



Odds ratios del modelo:

Variable	Coeficiente	Odds ratio	Interpretación
precio_sobre_mediana	−1.730	0.177	Los artículos caros tienen mucha menor probabilidad de venderse en mayoreo
edo_cdmx	−1.662	0.190	Los clientes de CDMX tienen menor probabilidad de comprar en mayoreo
marca_vita	−0.992	0.371	La marca Vita tiende menos al mayoreo
marca_vita	0.426	1.531	La marca Aidite aumenta la probabilidad de mayoreo
edo_puebla	−0.107	0.899	Efecto casi nulo

7. Conclusiones

- Las ventas por artículo se explican principalmente por las unidades vendidas y el precio. El modelo múltiple las describe casi a la perfección, aunque en parte es así por construcción, ya que las ventas son precio por unidades.
- Agregar el precio al modelo corrigió el coeficiente de las unidades (de 0.949 a 0.988) y mostró que el modelo simple lo subestimaba por omitir una variable relevante.
- En la regresión logística, ignorar el desbalance de clases hace que el modelo no detecte ningún caso de mayoreo. La reponderación de clases y el oversampling resuelven el problema con resultados equivalentes.
- Las ventas de mayoreo se concentran en artículos de precio bajo, en clientes fuera de la Ciudad de México y en marcas como Aidite.

8. Limitaciones

- El AUC de 0.71 es moderado y la precisión es baja (0.22), por lo que el modelo sirve para identificar posibles clientes o ventas de mayoreo, no para decidir por sí solo.
- El umbral de 5 unidades para definir mayoreo fue una decisión propia; con otro umbral los resultados cambiarían.
- Los datos de ventas cubren únicamente de abril a agosto de 2026.
- Solo 1,290 de los 2,951 artículos del inventario tuvieron ventas en el periodo, por lo que los modelos lineales se basan en los artículos con movimiento.